

Cloud Architecture Guidelines

Catálogo estructurado de lineamientos para RAG y validación de diagramas de arquitectura

Versión 1.0 | Proof of Concept local

Uso previsto: cada regla debe indexarse como una unidad independiente y conservar su ID y metadatos.

1. Objetivo del documento

Establecer reglas verificables para evaluar diseños de arquitectura cloud a partir de diagramas y contexto textual, utilizando exclusivamente el conocimiento de este documento.

2. Alcance del especialista

- Diseño cloud native y separación de responsabilidades.
- Stateless, persistencia externa y escalamiento horizontal.
- Elasticidad, alta disponibilidad y distribución entre dominios de fallo.
- Configuración, secretos, observabilidad, recuperación y consumo de recursos.

3. Fuera de alcance

- Configuración detallada de servidores, redes o clústeres; corresponde a Infrastructure.
- Semántica de APIs, eventos, contratos o brokers; corresponde a Integration.
- Validaciones de código fuente o controles no representados en el diagrama.

4. Estados de evaluación

Estado	Criterio
CUMPLE	La arquitectura contiene evidencia suficiente y explícita de que la regla se respeta.
NO CUMPLE	La arquitectura contiene evidencia explícita que contradice la regla.
NO HAY EVIDENCIA	El diagrama no muestra la información necesaria. La ausencia visual no debe interpretarse automáticamente como incumplimiento.
NO APLICA	La regla no corresponde al tipo de componente, escenario o alcance representado.

5. Instrucciones para el agente especialista

1. Analizar únicamente desde la perspectiva cloud.
2. Recuperar solo reglas relevantes a los componentes observados.
3. No marcar incumplimiento cuando la evidencia visual sea insuficiente.
4. Justificar cada hallazgo con ruleId y evidencia concreta.
5. No recomendar tecnologías específicas salvo que la regla las mencione como ejemplo.

6. Convenciones para RAG y chunking

- Cada bloque delimitado por BEGIN RULE y END RULE debe indexarse como un chunk independiente.
- El ID, dominio, categoría, prioridad y tipo de verificación deben almacenarse como metadata del Vector Store.
- Las introducciones y explicaciones generales no deben competir con las reglas durante la recuperación de validaciones.
- El Retriever debe priorizar reglas cuyo campo “Aplica cuando” coincida con los componentes detectados en el diagrama.
- Una regla NON_VISUAL puede recuperarse para formular preguntas, pero no debe producir un incumplimiento basado únicamente en una imagen.

7. Catálogo de lineamientos Cloud

=== BEGIN RULE CLOUD-DOMAIN-001 ===

CLOUD-DOMAIN-001 — Responsabilidad única por servicio

Dominio Cloud	Categoría Cloud Native	Prioridad Alta	Obligatoriedad Obligatorio
Tipo de verificación PARTIAL	Aplicabilidad Servicios y microservicios	Versión 1.0	Estado Activo

Objetivo: Favorecer servicios mantenibles, independientes y con alta cohesión.

Regla: Cada servicio debe representar una capacidad de negocio o responsabilidad técnica claramente delimitada y evitar agrupar funciones no relacionadas.

Aplica cuando: El diagrama contiene microservicios, APIs, workers o aplicaciones separadas.

No aplica cuando: La arquitectura es un monolito deliberado o un componente técnico indivisible y se documenta como tal.

Evidencia visual esperada:

- Servicios con nombres de dominio diferenciados
- Límites explícitos entre capacidades
- Bases o contratos asociados a un servicio

Indicadores de cumplimiento:

- Cada servicio tiene un propósito reconocible
- No se observan servicios genéricos que concentran múltiples dominios
- Las dependencias coinciden con responsabilidades claras

Indicadores de incumplimiento:

- Un único servicio concentra pagos, clientes, inventario y reportes
- Servicios llamados “Core”, “Manager” o “General” reciben todas las conexiones sin delimitación
- Múltiples dominios dependen del mismo componente multifunción

Criterio de NO HAY EVIDENCIA: Si los nombres o límites de responsabilidad no aparecen, clasificar como NO HAY EVIDENCIA y solicitar descripción funcional.

Riesgo asociado: Cambios amplios, baja mantenibilidad, despliegues coordinados y dificultad para escalar capacidades de forma independiente.

Recomendación: Dividir por capacidades de negocio o responsabilidades técnicas coherentes y definir contratos explícitos entre servicios.

Preguntas de aclaración:

- ¿Qué responsabilidad de negocio posee cada servicio?
- ¿Qué cambios pueden desplegarse de manera independiente?

Etiquetas de recuperación: cloud native, microservicios, responsabilidad única, alta cohesión, dominio, servicio independiente

=== END RULE CLOUD-DOMAIN-001 ===

=== BEGIN RULE CLOUD-STATE-001 ===

CLOUD-STATE-001 — Servicios stateless

Dominio Cloud	Categoría Cloud Native	Prioridad Alta	Obligatoriedad Obligatorio para servicios escalables
Tipo de verificación PARTIAL	Aplicabilidad APIs, aplicaciones web y microservicios	Versión 1.0	Estado Activo

Objetivo: Permitir reemplazo, recuperación y escalamiento horizontal de instancias.

Regla: Los servicios que atienden solicitudes deben evitar mantener sesiones o estado de negocio exclusivamente en memoria o disco local.

Aplica cuando: Existen servicios replicables, APIs, frontends server-side o workers intercambiables.

No aplica cuando: El componente es una base de datos, caché, broker o almacén diseñado para conservar estado.

Evidencia visual esperada:

- Etiqueta stateless
- Múltiples instancias detrás de un balanceador
- Estado o sesión almacenado en un componente externo

Indicadores de cumplimiento:

- El servicio se declara stateless
- Cualquier instancia puede atender la solicitud
- El estado se ubica en un almacén externo

Indicadores de incumplimiento:

- El diagrama declara sesiones en memoria local
- Se exige afinidad de sesión sin alternativa
- El servicio depende de disco local para funcionar

Criterio de NO HAY EVIDENCIA: Si el manejo de sesiones o estado no está representado, clasificar como NO HAY EVIDENCIA.

Riesgo asociado: Pérdida de sesión, escalamiento limitado, recuperación compleja y dependencia de instancias específicas.

Recomendación: Externalizar sesiones y estado hacia un almacén distribuido o persistente.

Preguntas de aclaración:

- ¿Dónde se almacenan las sesiones?
- ¿Una instancia puede reemplazarse sin pérdida de información?

Etiquetas de recuperación: stateless, sesión, estado local, memoria, escalamiento horizontal, cloud native

=== END RULE CLOUD-STATE-001 ===

=== BEGIN RULE CLOUD-STATE-002 ===

CLOUD-STATE-002 — Estado compartido en componentes externos

Dominio Cloud	Categoría Persistencia	Prioridad Alta	Obligatoriedad Obligatorio cuando existe estado compartido
Tipo de verificación VISUAL	Aplicabilidad Servicios con sesiones, caché o estado compartido	Versión 1.0	Estado Activo

Objetivo: Centralizar el estado compartido en componentes diseñados para persistencia o distribución.

Regla: Las sesiones, cachés compartidas y estados requeridos por varias instancias deben residir en bases de datos, cachés distribuidas u otros servicios externos apropiados.

Aplica cuando: El diagrama representa múltiples instancias o necesidades de sesión compartida.

No aplica cuando: No existe estado compartido o el servicio es completamente stateless.

Evidencia visual esperada:

- Redis o caché distribuida
- Base de datos de sesión
- Almacén externo conectado a todas las réplicas

Indicadores de cumplimiento:

- Todas las instancias acceden al mismo almacén externo
- El almacén está identificado como persistente o distribuido

Indicadores de incumplimiento:

- Cada instancia conserva su propia sesión local
- El estado requerido está en volúmenes locales aislados
- No existe mecanismo de sincronización entre instancias

Criterio de NO HAY EVIDENCIA: Si el diagrama no muestra dónde se conserva el estado, usar NO HAY EVIDENCIA.

Riesgo asociado: Inconsistencia entre instancias, pérdida de sesión y errores al escalar o recuperar servicios.

Recomendación: Incorporar un almacén externo apropiado y diseñar la aplicación para no depender del almacenamiento local.

Preguntas de aclaración:

- ¿El estado debe compartirse entre réplicas?
- ¿Qué tecnología conserva las sesiones o caché?

Etiquetas de recuperación: estado externo, Redis, caché distribuida, sesión, persistencia, réplicas

=== END RULE CLOUD-STATE-002 ===

=== BEGIN RULE CLOUD-SCALE-001 ===

CLOUD-SCALE-001 — Escalamiento horizontal de servicios

Dominio Cloud	Categoría Escalabilidad	Prioridad Crítica	Obligatoriedad Obligatorio para cargas variables o críticas
Tipo de verificación VISUAL	Aplicabilidad Servicios de aplicación con demanda variable	Versión 1.0	Estado Activo

Objetivo: Incrementar capacidad agregando instancias sin rediseñar la aplicación.

Regla: Los servicios que atienden carga variable deben poder ejecutarse en múltiples instancias detrás de un mecanismo de distribución.

Aplica cuando: El diagrama muestra APIs, frontends, workers o microservicios con tráfico concurrente.

No aplica cuando: El componente es estrictamente singleton por naturaleza y existe una justificación documentada.

Evidencia visual esperada:

- Múltiples réplicas
- Grupo de instancias
- Kubernetes Deployment
- Auto Scaling Group
- Balanceador de carga

Indicadores de cumplimiento:

- Existen dos o más instancias o una capacidad declarada de réplica
- El tráfico se distribuye entre instancias
- No existe dependencia visible de una instancia fija

Indicadores de incumplimiento:

- Se muestra una única instancia como única ruta para toda la carga

- La aplicación depende explícitamente de escalamiento vertical
- No existe mecanismo de distribución para múltiples réplicas

Criterio de NO HAY EVIDENCIA: Si el número de instancias no se representa, clasificar como NO HAY EVIDENCIA.

Riesgo asociado: Saturación, degradación bajo carga y crecimiento limitado por capacidad física.

Recomendación: Agregar capacidad horizontal y un mecanismo de balanceo o particionamiento acorde al componente.

Preguntas de aclaración:

- ¿Cuántas instancias se desplegarán?
- ¿Cómo se distribuye el tráfico?
- ¿El servicio puede escalar sin cambios de código?

Etiquetas de recuperación: escalamiento horizontal, réplicas, instancias, balanceador, auto scaling, capacidad

=== END RULE CLOUD-SCALE-001 ===

=== BEGIN RULE CLOUD-ELASTIC-001 ===

CLOUD-ELASTIC-001 — Elasticidad según demanda

Dominio Cloud	Categoría Elasticidad	Prioridad Alta	Obligatoriedad Recomendado; obligatorio para demanda altamente variable
Tipo de verificación PARTIAL	Aplicabilidad Cargas variables, estacionales o impredecibles	Versión 1.0	Estado Activo

Objetivo: Ajustar el consumo de recursos a la demanda real.

Regla: La capacidad de los servicios debe poder aumentar y disminuir mediante políticas automáticas o mecanismos equivalentes cuando la demanda sea variable.

Aplica cuando: Existen servicios de cara al usuario, procesamiento por lotes variable o picos conocidos.

No aplica cuando: La carga es fija, pequeña y documentada, o el sistema no requiere adaptación automática.

Evidencia visual esperada:

- Autoscaler
- HPA
- Auto Scaling Group
- Serverless
- Cola que regula workers
- Política de escalamiento

Indicadores de cumplimiento:

- Existe un mecanismo explícito de escalamiento automático
- El número de instancias puede reducirse cuando disminuye la carga

Indicadores de incumplimiento:

- Capacidad fija para una carga declarada como variable
- Dependencia exclusiva de aumento manual de CPU o memoria
- No existe mecanismo de absorción de picos

Criterio de NO HAY EVIDENCIA: Si el diagrama no muestra políticas o mecanismos de elasticidad, usar NO HAY EVIDENCIA.

Riesgo asociado: Sobrecosto en baja demanda o degradación durante picos.

Recomendación: Configurar escalamiento basado en métricas, longitud de cola o concurrencia, con límites mínimos y máximos.

Preguntas de aclaración:

- ¿Qué métrica activa el escalamiento?
- ¿Cuál es el rango mínimo y máximo de instancias?

Etiquetas de recuperación: elasticidad, autoscaling, HPA, serverless, picos de carga, demanda

=== END RULE CLOUD-ELASTIC-001 ===

=== BEGIN RULE CLOUD-HA-001 ===

CLOUD-HA-001 — Redundancia de componentes críticos

Dominio Cloud	Categoría Alta disponibilidad	Prioridad Crítica	Obligatoriedad Obligatorio
Tipo de verificación VISUAL	Aplicabilidad Componentes críticos de aplicación	Versión 1.0	Estado Activo

Objetivo: Evitar que una única instancia interrumpa el servicio.

Regla: Los componentes críticos deben ejecutarse en múltiples instancias o contar con un mecanismo equivalente de redundancia.

Aplica cuando: El diagrama contiene gateways, APIs, servicios de negocio, bases de datos o componentes centrales.

No aplica cuando: El componente es temporal, no crítico o pertenece únicamente a un entorno local de desarrollo.

Evidencia visual esperada:

- Múltiples instancias
- Réplicas
- Clúster
- Primario y réplica
- Servicio administrado multi-instancia

Indicadores de cumplimiento:

- Se muestran múltiples instancias del componente
- Existe un mecanismo explícito de failover o redundancia

Indicadores de incumplimiento:

- Una única instancia crítica concentra todo el tráfico
- Una única base de datos sin réplica ni alternativa
- El diagrama identifica un singleton sin recuperación

Criterio de NO HAY EVIDENCIA: Si no se muestra cardinalidad o redundancia, usar NO HAY EVIDENCIA.

Riesgo asociado: Punto único de falla e interrupción total ante una caída.

Recomendación: Agregar réplicas, failover y distribución de tráfico adecuados al tipo de componente.

Preguntas de aclaración:

- ¿El componente es crítico?
- ¿Cuántas réplicas existirán?
- ¿Cómo ocurre el failover?

Etiquetas de recuperación: alta disponibilidad, redundancia, réplicas, failover, punto único de falla

=== END RULE CLOUD-HA-001 ===

=== BEGIN RULE CLOUD-HA-002 ===

CLOUD-HA-002 — Distribución entre dominios de fallo

Dominio Cloud	Categoría Resiliencia	Prioridad Crítica	Obligatoriedad Obligatorio para componentes críticos
Tipo de verificación VISUAL	Aplicabilidad Despliegues productivos críticos	Versión 1.0	Estado Activo

Objetivo: Reducir fallos correlacionados de zona, nodo o dominio físico.

Regla: Las réplicas críticas deben distribuirse entre dominios de fallo independientes, como zonas de disponibilidad o nodos separados.

Aplica cuando: Existen múltiples instancias de un componente crítico.

No aplica cuando: El entorno no productivo no requiere tolerancia zonal y está documentado.

Evidencia visual esperada:

- Múltiples zonas
- Regiones o zonas diferenciadas
- Nodos separados
- Anti-affinity
- Topología distribuida

Indicadores de cumplimiento:

- Las réplicas están en al menos dos dominios de fallo
- La arquitectura muestra distribución zonal o equivalente

Indicadores de incumplimiento:

- Todas las réplicas están en una única zona o nodo
- El balanceador dirige a instancias ubicadas en el mismo dominio de fallo

Criterio de NO HAY EVIDENCIA: Si el diagrama no representa zonas, nodos o dominios de fallo, usar NO HAY EVIDENCIA.

Riesgo asociado: Una falla de zona o nodo puede afectar simultáneamente todas las réplicas.

Recomendación: Distribuir réplicas y datos entre dominios de fallo independientes.

Preguntas de aclaración:

- ¿En qué zonas se desplegarán las réplicas?
- ¿Existe afinidad o anti-affinity configurada?

Etiquetas de recuperación: zonas de disponibilidad, dominio de fallo, multi-AZ, anti-affinity, resiliencia

=== END RULE CLOUD-HA-002 ===

=== BEGIN RULE CLOUD-LB-001 ===

CLOUD-LB-001 — Distribución de tráfico entre instancias

Dominio Cloud	Categoría Alta disponibilidad	Prioridad Alta	Obligatoriedad Obligatorio cuando existen múltiples instancias
Tipo de verificación VISUAL	Aplicabilidad Servicios replicados que reciben tráfico	Versión 1.0	Estado Activo

Objetivo: Evitar conexiones directas y distribuir solicitudes de forma controlada.**Regla:** Los servicios con múltiples instancias deben exponerse mediante un balanceador, gateway, service mesh o mecanismo equivalente.**Aplica cuando:** El diagrama muestra dos o más instancias consumidoras de tráfico.**No aplica cuando:** Las instancias no reciben tráfico de red, por ejemplo workers que consumen una cola particionada.**Evidencia visual esperada:**

- Load Balancer
- API Gateway
- Kubernetes Service
- Ingress
- Service mesh
- Consumer group

Indicadores de cumplimiento:

- El tráfico entra por un punto de distribución
- Las instancias no están conectadas directamente a clientes externos

Indicadores de incumplimiento:

- Clientes conectados manualmente a instancias individuales
- Múltiples instancias sin mecanismo de distribución
- Una sola instancia recibe todo el tráfico aunque existen réplicas

Criterio de NO HAY EVIDENCIA: Si el método de distribución no se representa, usar NO HAY EVIDENCIA.**Riesgo asociado:** Desbalance, sesiones inconsistentes y pérdida de disponibilidad.**Recomendación:** Incorporar un mecanismo de distribución con health checks y políticas acordes al protocolo.**Preguntas de aclaración:**

- ¿Qué componente distribuye el tráfico?
- ¿El balanceador verifica la salud de las instancias?

Etiquetas de recuperación: balanceador, load balancer, gateway, ingress, distribución de tráfico, réplicas

=== END RULE CLOUD-LB-001 ===

=== BEGIN RULE CLOUD-DECOUPLE-001 ===

CLOUD-DECOUPLE-001 — Desacoplamiento entre componentes

Dominio Cloud	Categoría Desacoplamiento	Prioridad Alta	Obligatoriedad Obligatorio
Tipo de verificación VISUAL	Aplicabilidad Sistemas con múltiples servicios o dependencias	Versión 1.0	Estado Activo

Objetivo: Reducir propagación de fallos y permitir evolución independiente.**Regla:** Los componentes deben comunicarse mediante interfaces definidas y evitar dependencias directas innecesarias o cadenas síncronas extensas.**Aplica cuando:** El diagrama contiene varios servicios, integraciones o flujos de negocio.**No aplica cuando:** La interacción directa es simple, local y necesaria para una respuesta inmediata.**Evidencia visual esperada:**

- API o contrato explícito
- Broker o cola
- Eventos
- Gateway
- Capa de integración

Indicadores de cumplimiento:

- Las dependencias siguen interfaces visibles
- Los procesos largos usan mensajería o eventos cuando corresponde
- No se observa acceso a internals de otro servicio

Indicadores de incumplimiento:

- Conexiones punto a punto excesivas
- Cadena síncrona larga para completar una operación
- Acceso directo a almacenamiento interno de otro servicio

Criterio de NO HAY EVIDENCIA: Si el propósito o protocolo de las conexiones no aparece, usar NO HAY EVIDENCIA.

Riesgo asociado: Efecto cascada, cambios coordinados y baja resiliencia.

Recomendación: Introducir contratos, mensajería o intermediación solo donde reduzca acoplamiento real.

Preguntas de aclaración:

- ¿La operación requiere respuesta inmediata?
- ¿Qué ocurre si un servicio dependiente está caído?

Etiquetas de recuperación: desacoplamiento, bajo acoplamiento, eventos, cola, dependencias, resiliencia

=== END RULE CLOUD-DECOUPLE-001 ===

=== BEGIN RULE CLOUD-CONFIG-001 ===

CLOUD-CONFIG-001 — Configuración externa al código

Dominio Cloud	Categoría Configuración	Prioridad Alta	Obligatoriedad Obligatorio
Tipo de verificación PARTIAL	Aplicabilidad Aplicaciones desplegadas en múltiples ambientes	Versión 1.0	Estado Activo

Objetivo: Permitir cambios de configuración sin recompilar ni modificar el código.

Regla: La configuración dependiente del ambiente debe almacenarse fuera del código y proporcionarse mediante variables de entorno o servicios de configuración.

Aplica cuando: Existen ambientes, endpoints, parámetros o comportamientos variables.

No aplica cuando: El valor es una constante de dominio inmutable y no una configuración operativa.

Evidencia visual esperada:

- Config Server
- Variables de entorno
- ConfigMap
- Parámetros externos
- Servicio de configuración

Indicadores de cumplimiento:

- El diagrama identifica un origen externo de configuración
- Las aplicaciones reciben configuración por ambiente

Indicadores de incumplimiento:

- Configuración o endpoints incrustados explícitamente en la aplicación
- Un mismo artefacto no puede promoverse entre ambientes

Criterio de NO HAY EVIDENCIA: Si el diagrama no representa configuración, usar NO HAY EVIDENCIA.

Riesgo asociado: Errores por ambiente, despliegues innecesarios y exposición accidental de parámetros.

Recomendación: Externalizar la configuración y mantener el artefacto desplegable independiente del ambiente.

Preguntas de aclaración:

- ¿Dónde se administran los parámetros por ambiente?
- ¿El mismo artefacto se despliega en todos los ambientes?

Etiquetas de recuperación: configuración externa, variables de entorno, ConfigMap, config server, ambientes

=== END RULE CLOUD-CONFIG-001 ===

=== BEGIN RULE CLOUD-SECRET-001 ===

CLOUD-SECRET-001 — Gestión externa de secretos

Dominio Cloud	Categoría Seguridad	Prioridad Crítica	Obligatoriedad Obligatorio
Tipo de verificación PARTIAL	Aplicabilidad Aplicaciones con credenciales, llaves o tokens	Versión 1.0	Estado Activo

Objetivo: Evitar exposición de credenciales y facilitar rotación controlada.

Regla: Los secretos deben almacenarse y entregarse mediante un gestor de secretos o mecanismo seguro equivalente; no deben residir en código o imágenes.

Aplica cuando: El sistema accede a bases de datos, APIs protegidas, certificados o servicios autenticados.

No aplica cuando: No existen secretos requeridos por el componente.

Evidencia visual esperada:

- Secret Manager
- Vault
- Kubernetes Secret con protección adecuada
- HSM o KMS
- Referencia a secreto externo

Indicadores de cumplimiento:

- Existe un gestor central de secretos
- Los componentes consumen referencias y no valores embebidos

Indicadores de incumplimiento:

- Credenciales escritas en el código o imagen
- Archivo de configuración con secretos visibles
- Secretos compartidos sin gestión central

Criterio de NO HAY EVIDENCIA: Si el diagrama no representa gestión de secretos, usar NO HAY EVIDENCIA; no inferir exposición.

Riesgo asociado: Compromiso de credenciales, accesos no autorizados y rotación compleja.

Recomendación: Centralizar secretos, aplicar menor privilegio y habilitar rotación.

Preguntas de aclaración:

- ¿Dónde se guardan las credenciales?
- ¿Cómo se rotan y auditan los secretos?

Etiquetas de recuperación: secret manager, Vault, credenciales, secreto, rotación, KMS

=== END RULE CLOUD-SECRET-001 ===

=== BEGIN RULE CLOUD-SEC-001 ===

CLOUD-SEC-001 — Cifrado de comunicaciones y datos

Dominio Cloud	Categoría Seguridad	Prioridad Crítica	Obligatoriedad Obligatorio
Tipo de verificación PARTIAL	Aplicabilidad Flujos con datos sensibles o tráfico de red	Versión 1.0	Estado Activo

Objetivo: Proteger confidencialidad e integridad de la información.

Regla: Las comunicaciones deben utilizar cifrado en tránsito y los almacenes persistentes deben aplicar cifrado en reposo cuando corresponda.

Aplica cuando: Existen conexiones de red o almacenamiento de información sensible.

No aplica cuando: La información es pública y el riesgo ha sido aceptado formalmente.

Evidencia visual esperada:

- HTTPS/TLS
- mTLS
- Enlace cifrado
- Base de datos cifrada
- KMS

Indicadores de cumplimiento:

- Los enlaces sensibles están etiquetados como TLS/HTTPS/mTLS
- El almacenamiento declara cifrado o integración con KMS

Indicadores de incumplimiento:

- Protocolos inseguros explícitos para información sensible
- Almacenamiento declarado sin cifrado

Criterio de NO HAY EVIDENCIA: Si el diagrama no muestra protocolos o cifrado, usar NO HAY EVIDENCIA.

Riesgo asociado: Intercepción, manipulación o exposición de datos.

Recomendación: Aplicar TLS en tránsito, cifrado en reposo y gestión central de llaves.

Preguntas de aclaración:

- ¿Qué protocolos protegen cada conexión?
- ¿Quién administra las llaves de cifrado?

Etiquetas de recuperación: TLS, HTTPS, mTLS, cifrado en reposo, KMS, seguridad

=== END RULE CLOUD-SEC-001 ===

=== BEGIN RULE CLOUD-OBS-001 ===

CLOUD-OBS-001 — Observabilidad de aplicación

Dominio Cloud	Categoría Observabilidad	Prioridad Alta	Obligatoriedad Obligatorio
Tipo de verificación PARTIAL	Aplicabilidad Servicios productivos	Versión 1.0	Estado Activo

Objetivo: Comprender comportamiento, rendimiento y fallos de extremo a extremo.

Regla: Los servicios deben producir logs, métricas y trazas correlacionables, y enviarlas a una plataforma de observabilidad.

Aplica cuando: El diagrama representa servicios productivos o distribuidos.

No aplica cuando: Prototipos desechables no productivos con alcance limitado.

Evidencia visual esperada:

- Plataforma de logs
- Sistema de métricas
- Tracing distribuido
- Alertas
- Agentes o collectors

Indicadores de cumplimiento:

- Se observan los tres pilares o una plataforma que los integra
- Los servicios envían telemetría de forma centralizada

Indicadores de incumplimiento:

- No existe ninguna ruta de telemetría en un diagrama operacional detallado
- Cada servicio conserva logs únicamente de forma local

Criterio de NO HAY EVIDENCIA: Si el diagrama es de alto nivel y no representa observabilidad, usar NO HAY EVIDENCIA.

Riesgo asociado: Detección tardía, diagnóstico lento y falta de trazabilidad.

Recomendación: Agregar instrumentación y centralización de logs, métricas y trazas.

Preguntas de aclaración:

- ¿Dónde se centraliza la telemetría?
- ¿Existe correlación entre solicitudes y eventos?

Etiquetas de recuperación: observabilidad, logging, métricas, tracing, alertas, telemetría

=== END RULE CLOUD-OBS-001 ===

=== BEGIN RULE CLOUD-RECOVERY-001 ===

CLOUD-RECOVERY-001 — Recuperación automática de servicios

Dominio Cloud	Categoría Resiliencia	Prioridad Alta	Obligatoriedad Obligatorio para servicios críticos
Tipo de verificación PARTIAL	Aplicabilidad Servicios críticos y orquestados	Versión 1.0	Estado Activo

Objetivo: Reducir intervención manual y tiempo de recuperación.

Regla: Los servicios críticos deben contar con reinicio, reemplazo o failover automático ante fallos detectables.

Aplica cuando: Existen instancias, contenedores, nodos o servicios administrados críticos.

No aplica cuando: El componente es manual, temporal o no crítico.

Evidencia visual esperada:

- Self-healing
- Health check
- Restart policy
- Failover
- Orquestador
- Managed service

Indicadores de cumplimiento:

- Existe un mecanismo explícito de recuperación automática
- La detección de salud está conectada al reemplazo o failover

Indicadores de incumplimiento:

- La recuperación depende exclusivamente de intervención humana
- No existe mecanismo de detección para un componente crítico

Criterio de NO HAY EVIDENCIA: Si el mecanismo de recuperación no aparece, usar NO HAY EVIDENCIA.

Riesgo asociado: Tiempo de caída prolongado y errores operativos.

Recomendación: Configurar health checks, políticas de reinicio, réplicas y failover automático.

Preguntas de aclaración:

- ¿Qué detecta la falla?
- ¿Qué acción automática se ejecuta?

Etiquetas de recuperación: self-healing, recuperación automática, health check, failover, restart

=== END RULE CLOUD-RECOVERY-001 ===

=== BEGIN RULE CLOUD-CONTAINER-001 ===

CLOUD-CONTAINER-001 — Empaquetado independiente en contenedores

Dominio Cloud	Categoría Contenedores	Prioridad Media	Obligatoriedad Recomendado
Tipo de verificación VISUAL	Aplicabilidad Servicios modernos desplegables	Versión 1.0	Estado Activo

Objetivo: Mejorar portabilidad, consistencia y despliegue independiente.

Regla: Los servicios independientes deben empaquetarse como unidades desplegables aisladas, preferentemente contenedores, cuando el contexto lo permita.

Aplica cuando: Existen microservicios, APIs o workers independientes.

No aplica cuando: La plataforma usa un servicio serverless o PaaS que ya abstrae el empaquetado.

Evidencia visual esperada:

- Contenedores
- Imágenes
- Pods
- Tasks
- Servicios serverless administrados

Indicadores de cumplimiento:

- Cada servicio se representa como unidad desplegable independiente
- El empaquetado no agrupa dominios no relacionados

Indicadores de incumplimiento:

- Un único contenedor ejecuta varios servicios independientes
- El despliegue requiere dependencias de máquina no controladas

Criterio de NO HAY EVIDENCIA: Si el diagrama no representa unidades de despliegue, usar NO HAY EVIDENCIA.

Riesgo asociado: Diferencias entre ambientes y despliegues acoplados.

Recomendación: Empaquetar cada servicio con sus dependencias o usar una plataforma administrada equivalente.

Preguntas de aclaración:

- ¿Cuál es la unidad de despliegue de cada servicio?
- ¿Los servicios se pueden publicar independientemente?

Etiquetas de recuperación: contenedores, Docker, imagen, unidad de despliegue, portabilidad

=== END RULE CLOUD-CONTAINER-001 ===

=== BEGIN RULE CLOUD-DATA-001 ===

CLOUD-DATA-001 — Evitar persistencia local en servicios efímeros

Dominio Cloud	Categoría Persistencia	Prioridad Alta	Obligatoriedad Obligatorio
Tipo de verificación VISUAL	Aplicabilidad Contenedores, instancias autoscalables o efímeras	Versión 1.0	Estado Activo

Objetivo: Evitar pérdida de datos al reemplazar o escalar instancias.

Regla: Los servicios efímeros no deben conservar datos persistentes únicamente en discos locales de la instancia o contenedor.

Aplica cuando: El diagrama contiene contenedores, pods o grupos de instancias reemplazables.

No aplica cuando: Los datos son temporales, reconstruibles y están identificados como caché local.

Evidencia visual esperada:

- Base de datos externa
- Object storage
- Volumen persistente
- Sistema de archivos administrado

Indicadores de cumplimiento:

- Los datos persistentes residen fuera de las instancias efímeras

- Los volúmenes son administrados o replicados

Indicadores de incumplimiento:

- Datos de negocio almacenados solo en disco local
- Contenedor con almacenamiento persistente interno no replicado

Criterio de NO HAY EVIDENCIA: Si no se representa la ubicación de datos, usar NO HAY EVIDENCIA.

Riesgo asociado: Pérdida de datos y bloqueo del escalamiento o reemplazo.

Recomendación: Mover persistencia a servicios durables y dejar el almacenamiento local solo para datos temporales.

Preguntas de aclaración:

- ¿Qué datos son persistentes?
- ¿Qué ocurre cuando una instancia se reemplaza?

Etiquetas de recuperación: persistencia local, disco local, object storage, volumen persistente, efímero

=== END RULE CLOUD-DATA-001 ===

=== BEGIN RULE CLOUD-COST-001 ===

CLOUD-COST-001 — Capacidad ajustada al consumo

Dominio Cloud	Categoría Optimización	Prioridad Media	Obligatoriedad Recomendado
Tipo de verificación PARTIAL	Aplicabilidad Cargas con variación o componentes costosos	Versión 1.0	Estado Activo

Objetivo: Evitar sobredimensionamiento sin comprometer objetivos de servicio.

Regla: Los componentes deben utilizar capacidades y modelos de consumo coherentes con la carga prevista, con posibilidad de ajuste cuando sea viable.

Aplica cuando: Existen servicios elásticos, procesamiento por demanda o recursos de alto costo.

No aplica cuando: La capacidad fija está justificada por requisitos regulatorios o técnicos.

Evidencia visual esperada:

- Autoscaling
- Serverless
- Escalado programado
- Clases de servicio diferenciadas
- Apagado de ambientes no productivos

Indicadores de cumplimiento:

- La capacidad puede ajustarse
- Existen límites y políticas de consumo
- Los entornos no productivos no replican costos innecesarios

Indicadores de incumplimiento:

- Recursos máximos permanentes para demanda baja y variable
- Duplicación de componentes sin justificación
- Ausencia explícita de límites de consumo

Criterio de NO HAY EVIDENCIA: Si el diagrama no contiene datos de capacidad o modelo de consumo, usar NO HAY EVIDENCIA.

Riesgo asociado: Costos innecesarios o falta de capacidad en picos.

Recomendación: Definir métricas de capacidad, límites, escalamiento y políticas por ambiente.

Preguntas de aclaración:

- ¿Cuál es el patrón de demanda?
- ¿Qué componentes pueden ajustar capacidad automáticamente?

Etiquetas de recuperación: costos, right sizing, autoscaling, serverless, consumo, capacidad

=== END RULE CLOUD-COST-001 ===

=== BEGIN RULE CLOUD-AUDIT-001 ===

CLOUD-AUDIT-001 — Trazabilidad de acciones privilegiadas

Dominio Cloud	Categoría Seguridad	Prioridad Alta	Obligatoriedad Obligatorio para producción
Tipo de verificación NON_VISUAL	Aplicabilidad Servicios y plataformas productivas	Versión 1.0	Estado Activo

Objetivo: Mantener evidencia de cambios y accesos relevantes.

Regla: Las acciones administrativas y de seguridad deben quedar registradas en mecanismos de auditoría centralizados y protegidos.

Aplica cuando: La solución opera en producción o gestiona información sensible.

No aplica cuando: Entornos locales desechables sin datos sensibles.

Evidencia visual esperada:

- Servicio de auditoría
- Audit logs
- SIEM
- Registro de cambios administrativos

Indicadores de cumplimiento:

- Existe una fuente central de auditoría
- Los eventos administrativos se envían a un repositorio protegido

Indicadores de incumplimiento:

- Se declara explícitamente ausencia de auditoría
- Los registros administrativos se almacenan solo en el componente modificado

Criterio de NO HAY EVIDENCIA: Una imagen rara vez permite confirmar cobertura y retención. Usar NO HAY EVIDENCIA salvo indicación explícita.

Riesgo asociado: Imposibilidad de investigar incidentes o demostrar cumplimiento.

Recomendación: Habilitar auditoría central, retención protegida y alertas para acciones críticas.

Preguntas de aclaración:

- ¿Qué acciones se auditan?
- ¿Cuál es la retención y quién puede modificar los registros?

Etiquetas de recuperación: auditoría, audit logs, SIEM, acciones privilegiadas, trazabilidad

=== END RULE CLOUD-AUDIT-001 ===

Catálogo resumido de reglas

ID	Título	Prioridad	Verificación
CLOUD-DOMAIN-001	Responsabilidad única por servicio	Alta	PARTIAL
CLOUD-STATE-001	Servicios stateless	Alta	PARTIAL
CLOUD-STATE-002	Estado compartido en componentes externos	Alta	VISUAL
CLOUD-SCALE-001	Escalamiento horizontal de servicios	Crítica	VISUAL
CLOUD-ELASTIC-001	Elasticidad según demanda	Alta	PARTIAL
CLOUD-HA-001	Redundancia de componentes críticos	Crítica	VISUAL
CLOUD-HA-002	Distribución entre dominios de fallo	Crítica	VISUAL
CLOUD-LB-001	Distribución de tráfico entre instancias	Alta	VISUAL
CLOUD-DECOUPLE-001	Desacoplamiento entre componentes	Alta	VISUAL
CLOUD-CONFIG-001	Configuración externa al código	Alta	PARTIAL
CLOUD-SECRET-001	Gestión externa de secretos	Crítica	PARTIAL
CLOUD-SEC-001	Cifrado de comunicaciones y datos	Crítica	PARTIAL
CLOUD-OBS-001	Observabilidad de aplicación	Alta	PARTIAL
CLOUD-RECOVERY-001	Recuperación automática de servicios	Alta	PARTIAL
CLOUD-CONTAINER-001	Empaquetado independiente en contenedores	Media	VISUAL
CLOUD-DATA-001	Evitar persistencia local en servicios efímeros	Alta	VISUAL
CLOUD-COST-001	Capacidad ajustada al consumo	Media	PARTIAL
CLOUD-AUDIT-001	Trazabilidad de acciones privilegiadas	Alta	NON_VISUAL

Límites de la validación visual

- Un diagrama puede omitir intencionalmente configuración, seguridad, telemetría o detalles de despliegue.
- La ausencia de un icono no demuestra que una capacidad no exista.
- Las reglas PARTIAL y NON_VISUAL deben producir preguntas de aclaración cuando falte evidencia.
- La validación debe considerar el nivel de detalle y propósito declarado del diagrama.

Criterio de salida del agente

La evaluación debe devolver una lista de hallazgos trazables. Cada hallazgo debe contener: ruleId, estado, evidencia observada, explicación, riesgo, recomendación, preguntas pendientes y fuente documental. El agente no debe utilizar conocimiento externo a este documento.